

# Simulador de Conversación

Aikiu — Documentación técnica

## ¿Qué es y para qué sirve?

Un sistema de prueba automática que simula conversaciones entre **Marta** (la usuaria) y **Clara** (el bot) sin tocar el bot de producción. Permite iterar el perfil de Clara rápidamente, midiendo calidad con criterios objetivos.

**El problema que resuelve:** antes, para saber si un cambio en el perfil mejoraba la conversación, había que probarlo manualmente con el bot real. Ahora se pueden correr decenas de iteraciones automáticas en minutos.

## Arquitectura: dos agentes

| Agente A — Marta (Gemini)                       | Agente B — Clara (cascada LLMs)              |
|-------------------------------------------------|----------------------------------------------|
| Simula a la usuaria usando<br>personas/marta.md | Simula al bot usando<br>perfil_simulacion.md |
| Modelo: gemini-2.5-flash                        | Groq → Gemini → OpenRouter                   |

Los logs de cada conversación se guardan en `simulador/logs/` como archivos `.jsonl`. El evaluador los lee y decide si actualizar el perfil.

## Cascada de LLMs (fallback automático)

Si un proveedor falla por límite diario de tokens (429) o error de servidor, el simulador pasa automáticamente al siguiente sin interrumpir la conversación. Cada turno del log registra qué backend respondió.

| # | Proveedor  | Modelo                     | Límite gratis   |
|---|------------|----------------------------|-----------------|
| 1 | Groq       | llama-3.3-70b-versatile    | 100k tokens/día |
| 2 | Gemini     | gemini-2.5-flash           | 1.500 req/día   |
| 3 | OpenRouter | openai/gpt-oss-120b:free   | compartido      |
| 4 | OpenRouter | google/gemma-4-31b-it:free | compartido      |
| 5 | OpenRouter | nvidia/nemotron-120b:free  | compartido      |

## Evaluador: 7 criterios gerontológicos

Después de cada simulación, Gemini evalúa la conversación de 0 a 10 en cada criterio. **El perfil solo se actualiza si el score supera al anterior.** Si baja, se descarta. Antes de sobrescribir, hace backup automático.

| Criterio                   | Qué mide                                                  |
|----------------------------|-----------------------------------------------------------|
| Voseo rioplatense          | ¿Usó 'querés/tenés/podés'? ¿Cero tuteo neutro?            |
| Ratio preguntas            | ¿Máximo una pregunta por turno?                           |
| Autorrevelación            | ¿Clara aportó datos/anécdotas propias antes de preguntar? |
| Respuesta a vulnerabilidad | ¿Priorizó salud/dolor sobre temas triviales?              |
| Sin eco/espejo             | ¿Evitó repetir textualmente las palabras de Marta?        |
| Cierre de negativas        | ¿Ante un 'no', cerró con calidez sin repreguntar?         |
| Tono gerontológico         | ¿Fue cálido, no infantilizante, no enciclopédico?         |

### Loop de iteraciones

El orquestador corre N ciclos de **simular** → **evaluar** → **(si mejora) actualizar perfil**. Al final, `perfil_simulacion.md` tiene la mejor versión encontrada.

```
python simulador/loop.py 10 marta 10 # 10 iteraciones, persona marta, 10 turnos
```

### Resultados obtenidos

Se corrieron 3 rondas (5 + 5 + 10 iteraciones). Mejores scores alcanzados:

| Score   | Mejora principal aplicada al perfil                           |
|---------|---------------------------------------------------------------|
| 10.0/10 | Énfasis en autorrevelación y estructura anti-interrogatorio   |
| 9.7/10  | Reglas de cierre de negativas y estructura ideal de respuesta |
| 9.0/10  | Anti-eco explícito + respuesta a preguntas directas de Marta  |

### Estructura de archivos

```
simulador/ ■■■ simulador.py # motor (2 agentes + cascada LLMs) ■■■ evaluador.py
# scoring + actualización del perfil ■■■ loop.py # orquestador N iteraciones ■■■
perfil_simulacion.md # perfil de prueba (no tocar a mano) ■■■ scores.jsonl #
historial de scores ■■■ logs/ # conversaciones completas (.jsonl) ■■■ personas/
■■■ marta.md # perfil detallado de la usuaria simulada
```

Los logs, scores y el perfil de simulación están en `.gitignore` — son artefactos locales. Solo se commitean los scripts y `marta.md`.